On-Device-AI on Jetson board

On-Device-AI on Jetson board

강의를 위한 기본 setting과 관련된 정보를 정리한 page.

배료 자료

codeXpert 과정참가 후 다운 받는다.

Jetson SDK image flashing

- NVIDIA SDK Manager를 이용하여 진행한다.
  - 강의의 목적에 맞게 Windows 환경에서 진행
- Windows SDK Manager를 통한 SSD flashing 과정은 여기를 참조한다.

수업 진도에 맞추어 아래 link를 참조하여 jetson board를 setup한다.

1. **Jetson 기본**
2. **Jetson Computer Vision 개발 환경**
3. **Jetson Docker setup on SSD**
4. **Jetson Ollama setup**
5. **Jetson Open WebUI**
6. **KCCI ip setup on terminal**

IP & Host Name setup

고정 IP setup: ubunut 기반

ssh terminal 환경에서 `nmcli`로 wired connection IP manual setup 방법

1. connection status

아래 명령으로 connection 정보를 확인한다. `NAME` 정보를 기반으로 setup을 진행한다.

```
    nmcli c show
```

`Wired connection 1`을 기반으로 진행 예

2. IP와 게이트웨이를 동시에 설정 (서브넷 마스크 /24 포함)

xx: 고정 ip 변호로 수정하고 아래 명령을 수행

```
sudo nmcli c modify "Wired connection 1" \
    ipv4.addresses 10.10.141.xx/24 \
    ipv4.gateway 10.10.141.254
```

3. 할당 방식을 '수동(manual)'으로 변경

```
sudo nmcli c modify "Wired connection 1" \
    ipv4.method manual
```

4. DNS도 같이 설정해주는 것이 좋습니다 (안 그러면 이름 해석이 안 될 수 있음)

```
sudo nmcli c modify "Wired connection 1" \
    ipv4.dns "8.8.8.8,8.8.4.4"
```

5. 설정 적용

```
sudo nmcli connection up "Wired connection 1"
```

Host Name setup

mDNS를 사용하여 연력하기 위해 고유의 Host Name을 지정한다.

1. 현재 호스트 이름 확인

터미널을 열고 아래 명령어를 입력하여 현재 이름을 확인합니다.

```
hostnamectl
```

2. 호스트 이름 변경

jetson-xxx(xxx 는 수강 번호)로 변경 예

```
sudo hostnamectl set-hostname jetson-000
```

3. hosts 파일 수정 (중요)

호스트 이름만 바꾸면 네트워크상에서 혼선이 생기거나, sudo 명령어를 쓸 때 unable to resolve host 에러가 발생할 수 있음. 이를 방지하기 위해 /etc/hosts 파일도 수정.

```
sudo vi /etc/hosts
```

파일이 열리면 보통 두 번째 줄에 있는 기존 이름을 새로운 이름으로 변경

- 수정 전: 127.0.1.1 ubuntu
- 수정 후: 127.0.1.1 jetson-000

4. 시스템 재부팅

변경 사항을 완전히 적용하려면 시스템을 재부팅 권장

```
sudo reboot
```

팁

- 이름 규칙: 호스트 이름에는 영문 소문자, 숫자, 하이픈(-)만 사용하는 것이 관례입니다. 공백이나 특수문자는 피한다.
- 확인: 재부팅 후 터미널 프롬프트(`user@jetson-000:~$`)에서 바뀐 이름을 바로 확인할 수 있다.

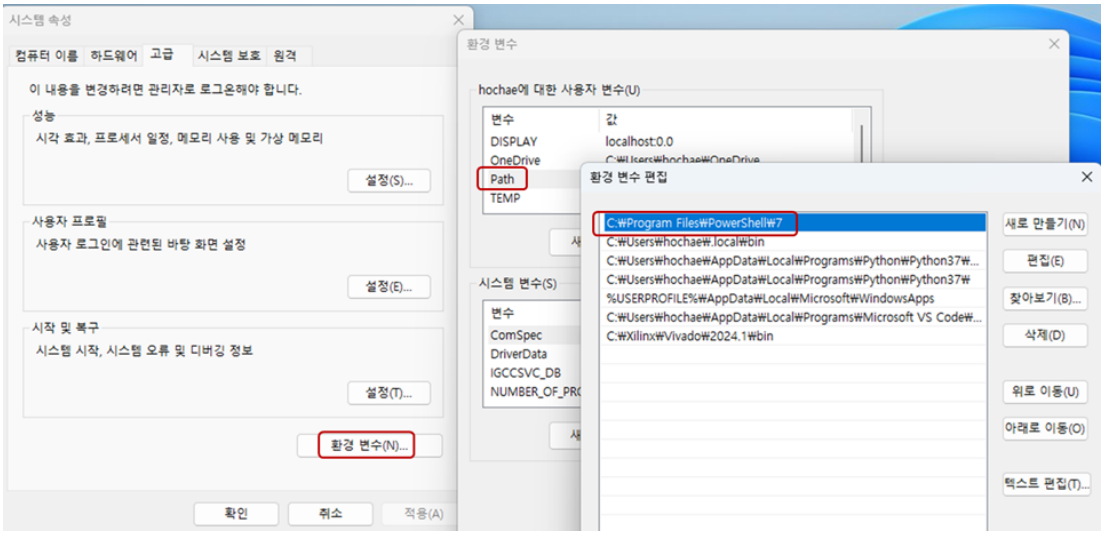
Jetson Image flashing on SSD w/ NVIDIA SDK manager

주의 사항

- NVIDIA SDK nanager는 기본적으로 linux 기반의 tool이다. 따라서 windows system에서도 WSL을 사용한다.
  - WSL을 먼저 install 하고 진행한다.
    - powershell에서 아래 명령으로 wsl을 install 한다.

```
wsl --install
```

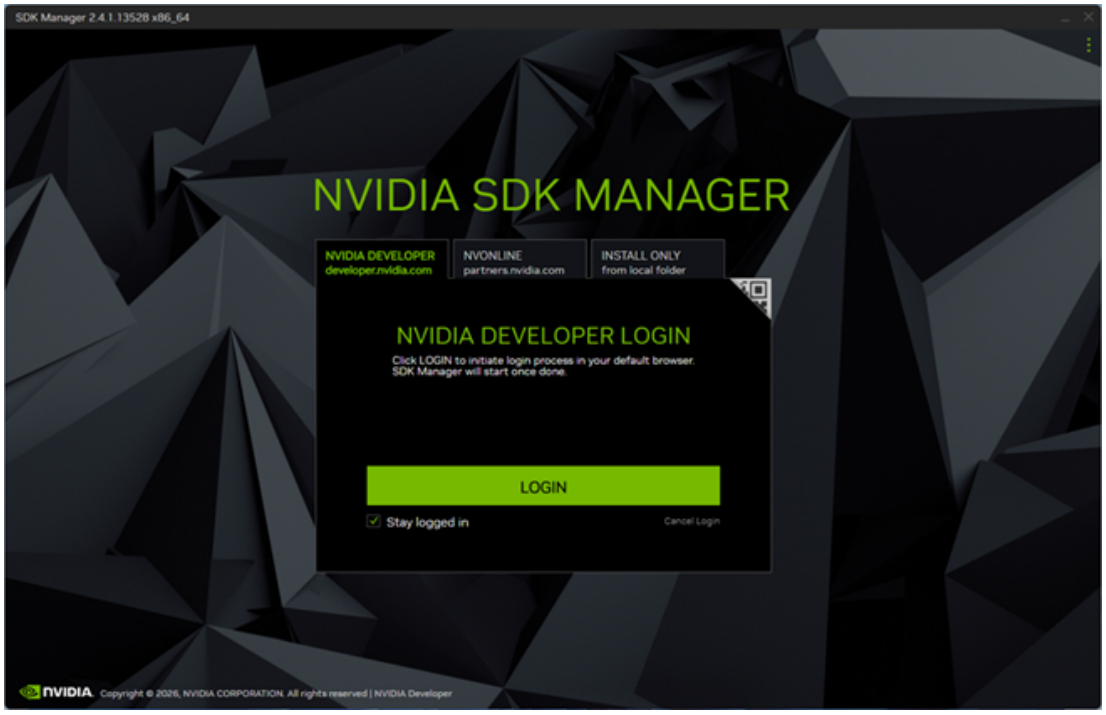
- WSL 환경하에서 USB port on/off를 진행하며 이 때 powershell을 사용한다.
  - powershell은 가장 최신인 7.6.x를 install 하기를 추천한다.
  - 제공한 `.msi`를 이용하여 설치 후 환경변수 PATH에 이 folder를 추가하고 우선권을 최상으로 한다.



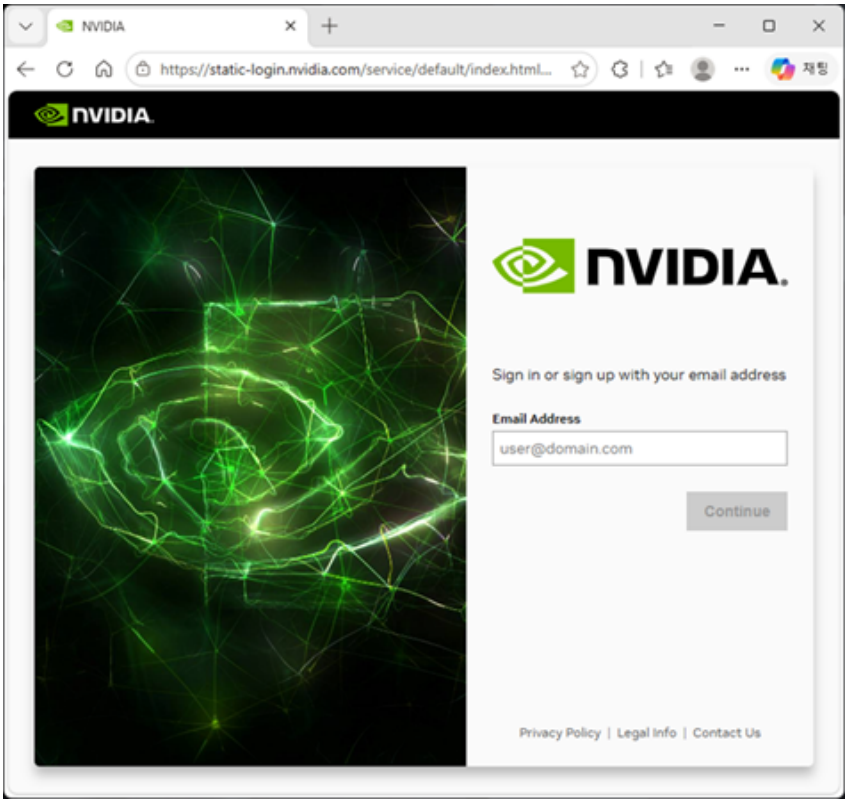
- Downloading 과 install을 동시 진행할 경우 시간이 많이 걸린다.
  - 수업에서는 먼저 Downloading을 진행하고 시차를 두고 install을 진행한다.

1. SDK manager 실행하고 login 후 Download 진행

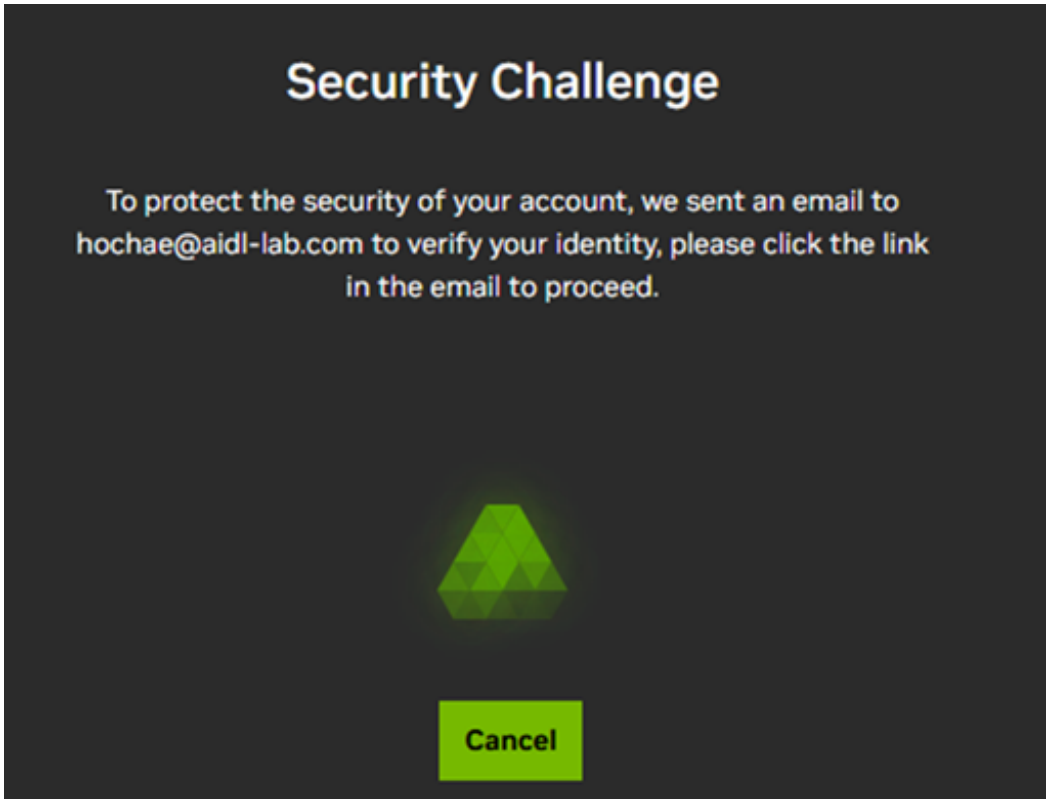
- 실행 초기화면



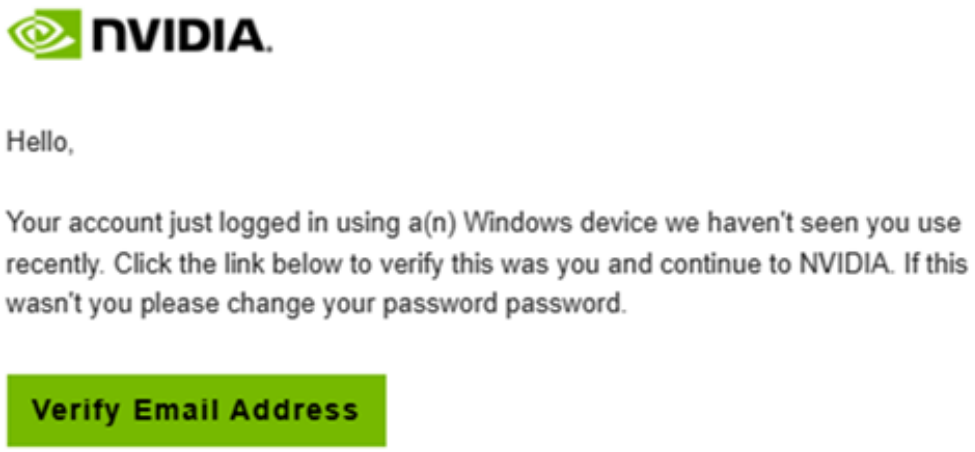
- login click -> login on web-browser (web browser): 계정이 없으면 만들어야 함



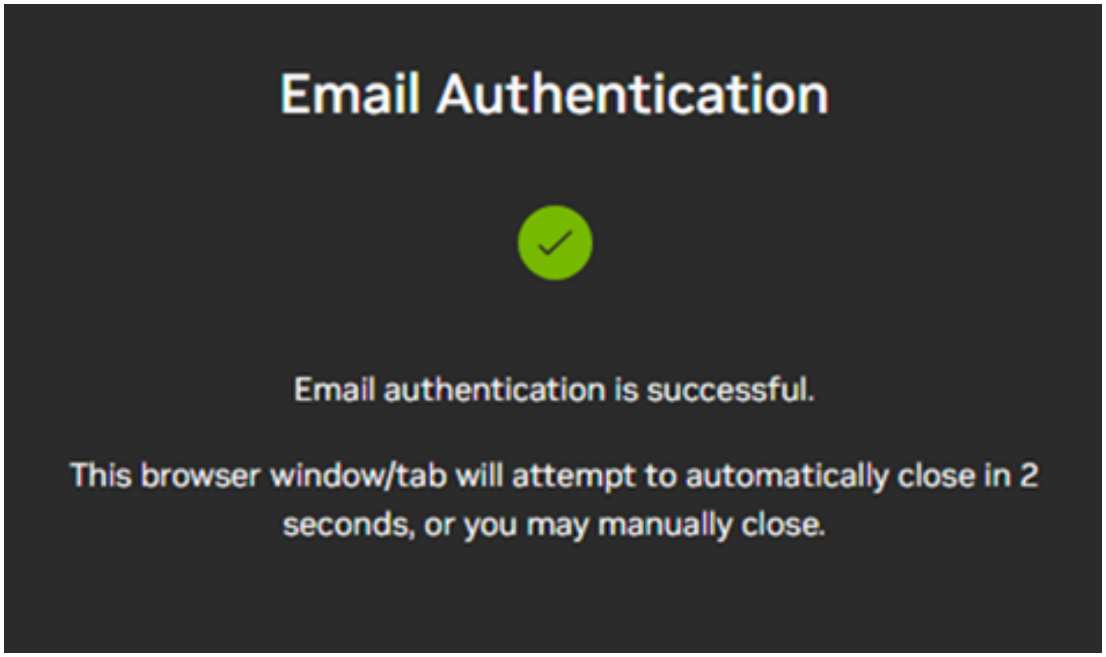
- mail을 확인하라는 message (web browser)



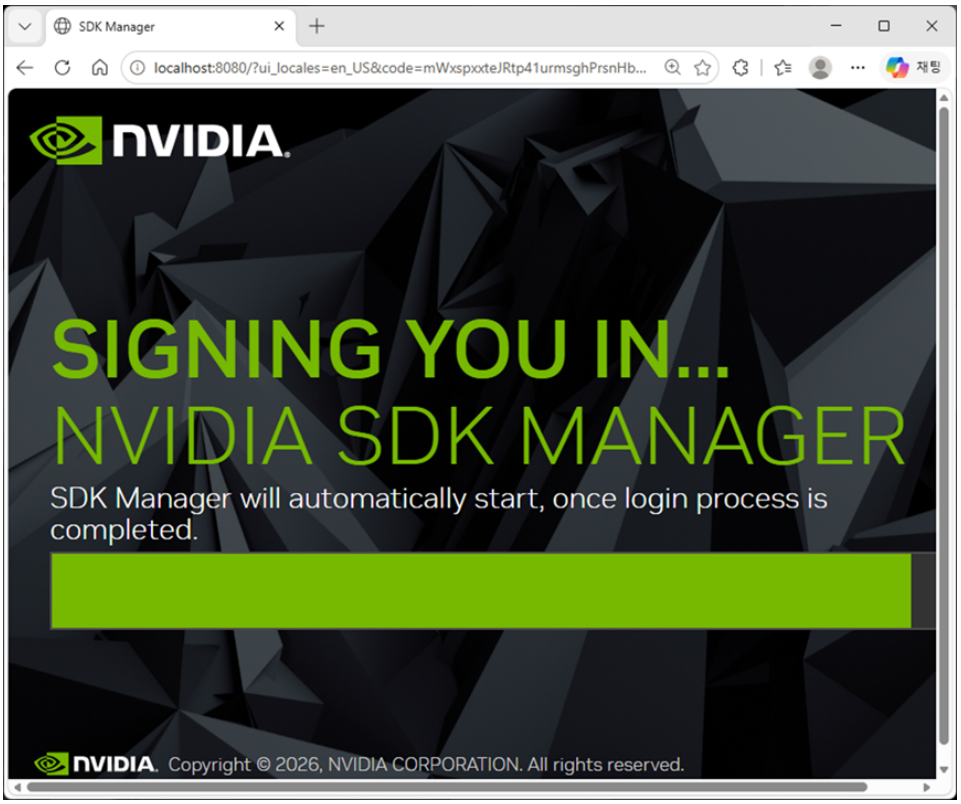
- NVIDIA에서 보내온 메일에서 `Verify`를 눌러 검증



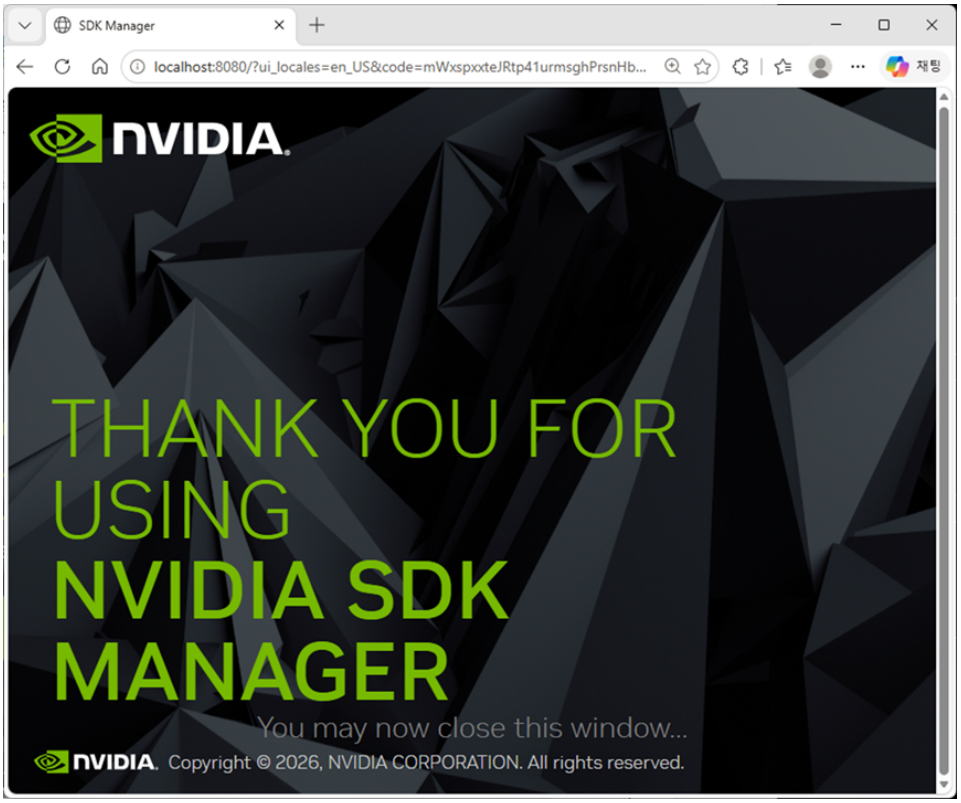
- Email Authentication 완료



- NVIDIA SDK signing 진행 (web browser)



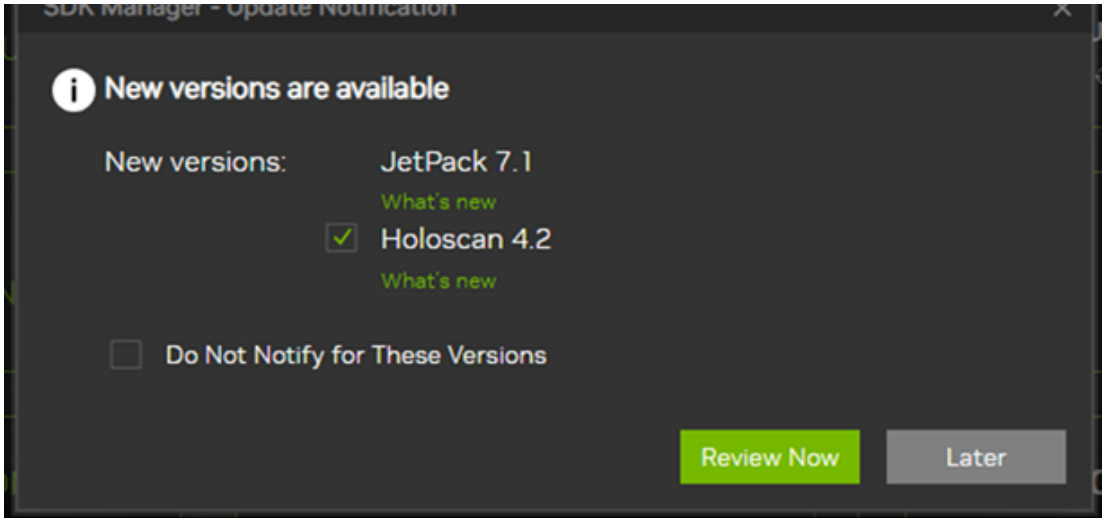
- SDK signing 완료 (web browser)



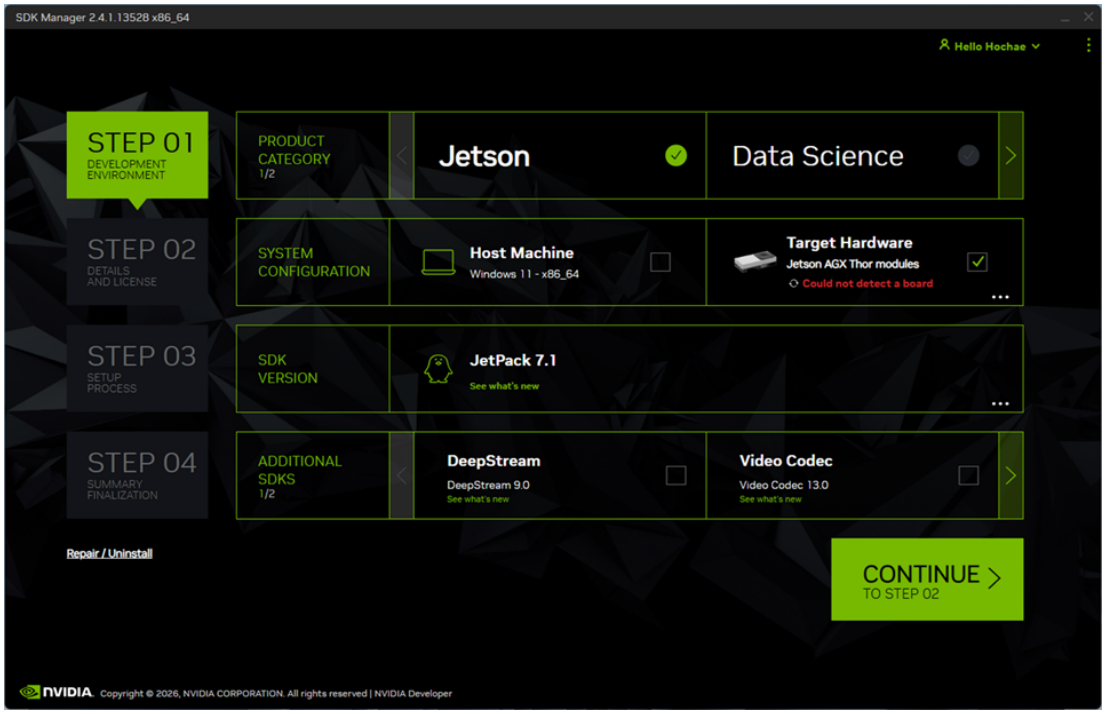
- SDK login 진행



- SDK login 완료 후 new version info : Later 선택



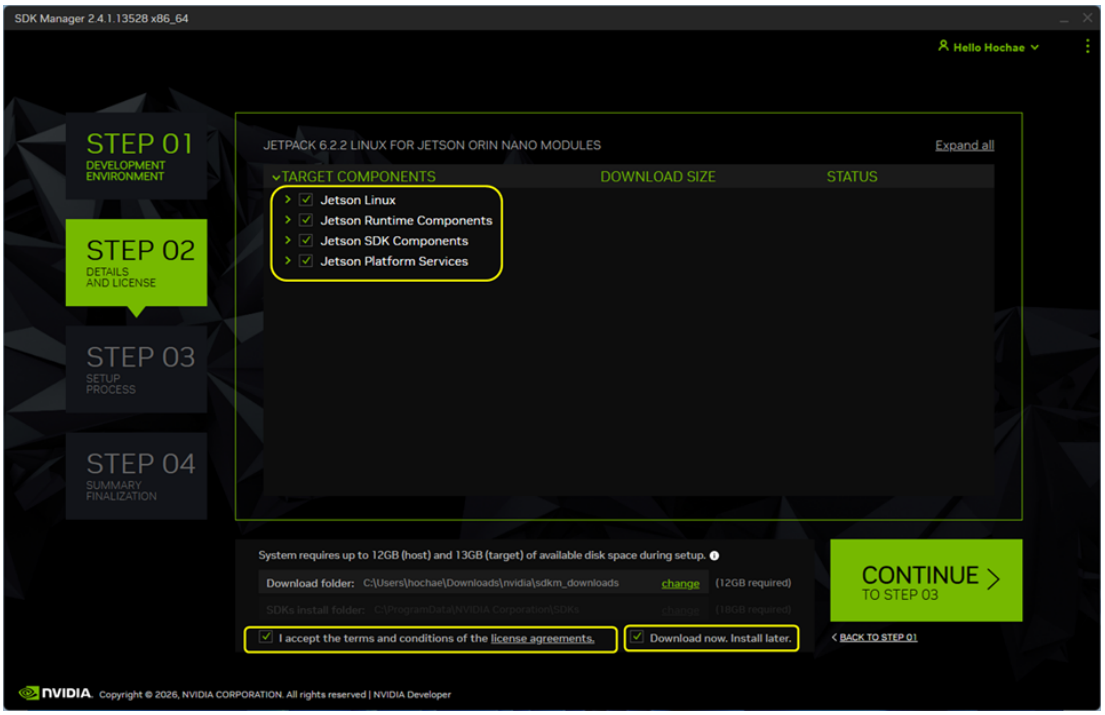
- SDK Step 01



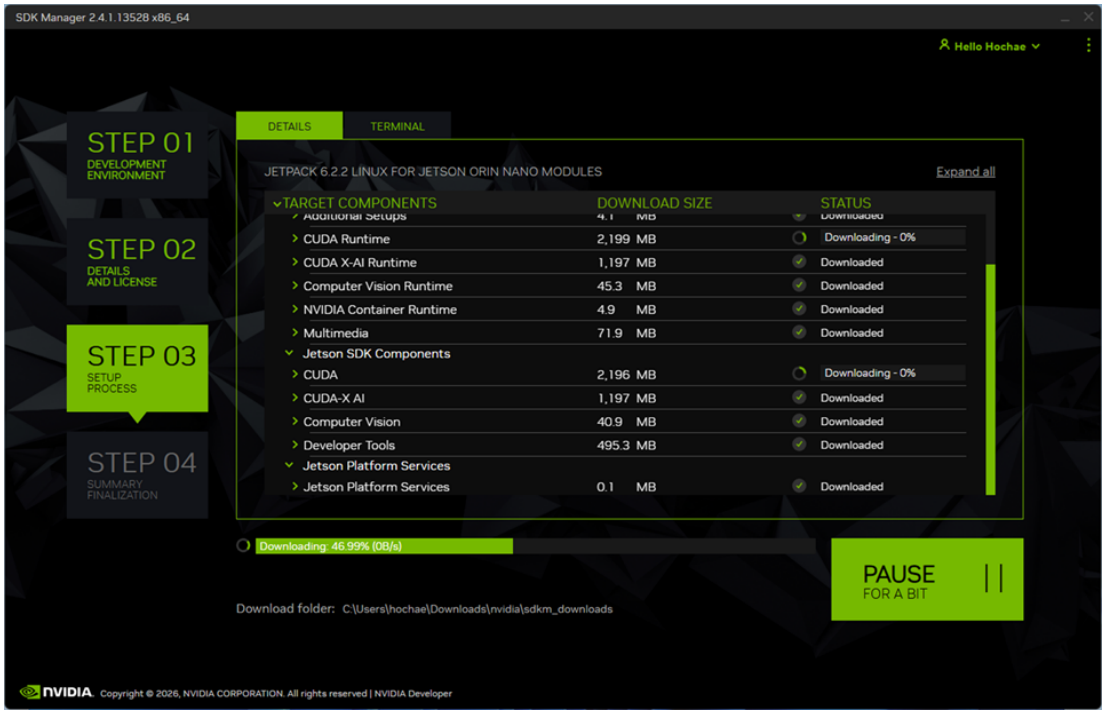
- SDK Step 01: Target Hardware를 진행 -> Jetson Orin Nano modules



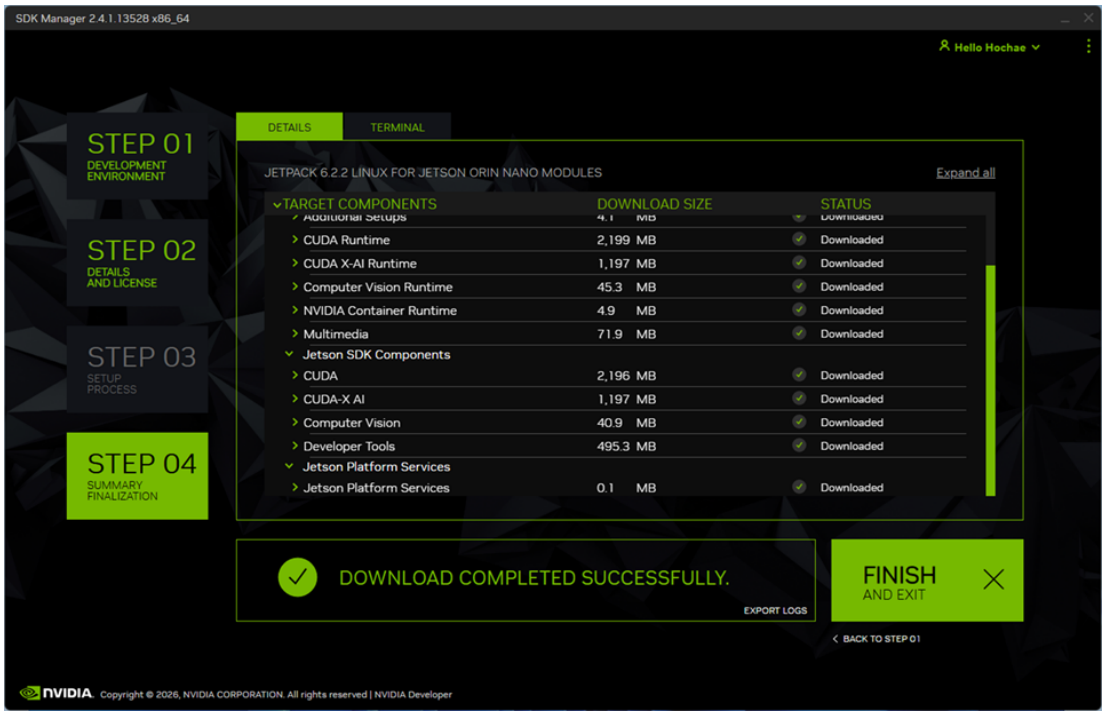
- SDK Step 02: TARGET COMPONENTS 모두를 선택, lincense와 Download 선택



- SDK Step 03: Download 진행

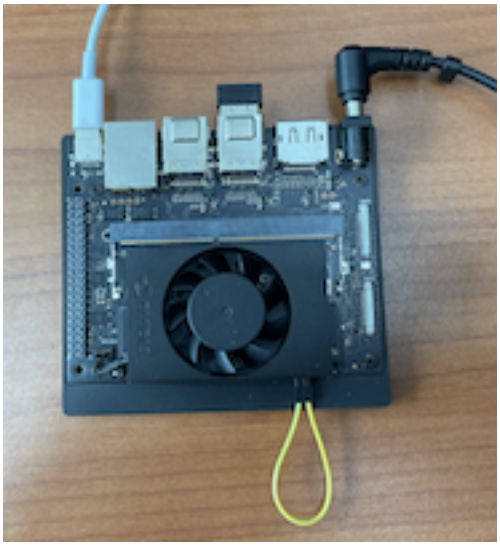


- SDK Step 04

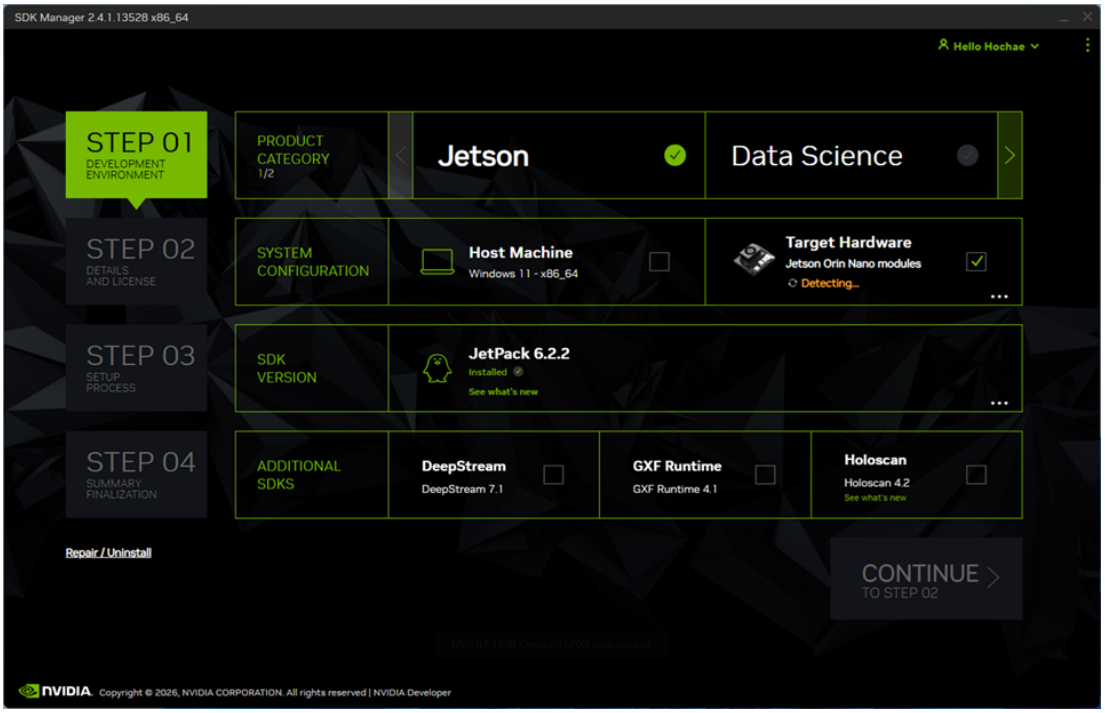


2. SSD flashing

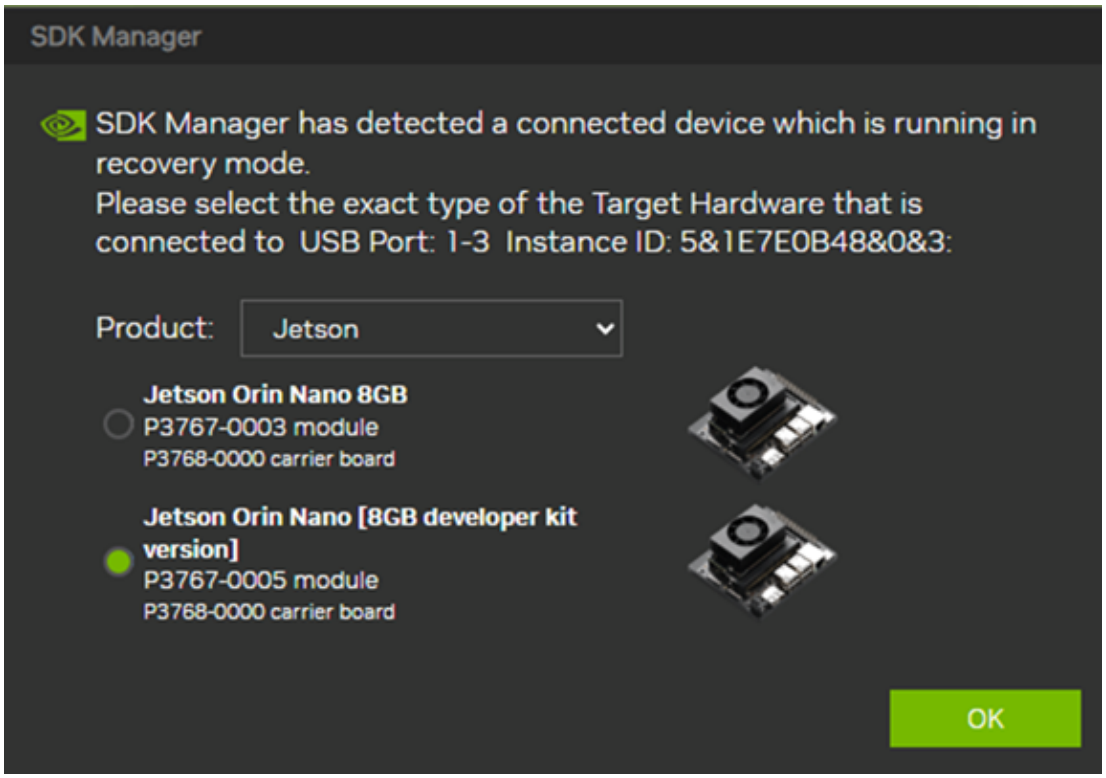
- Board 준비
  - image flashing 을 위해 Jetson을 Rescue mode로 setting
    - J14(Bustton Header) pin 10,Force Recoverypin을 GND에 jumper로 연결
  - USB port 연결



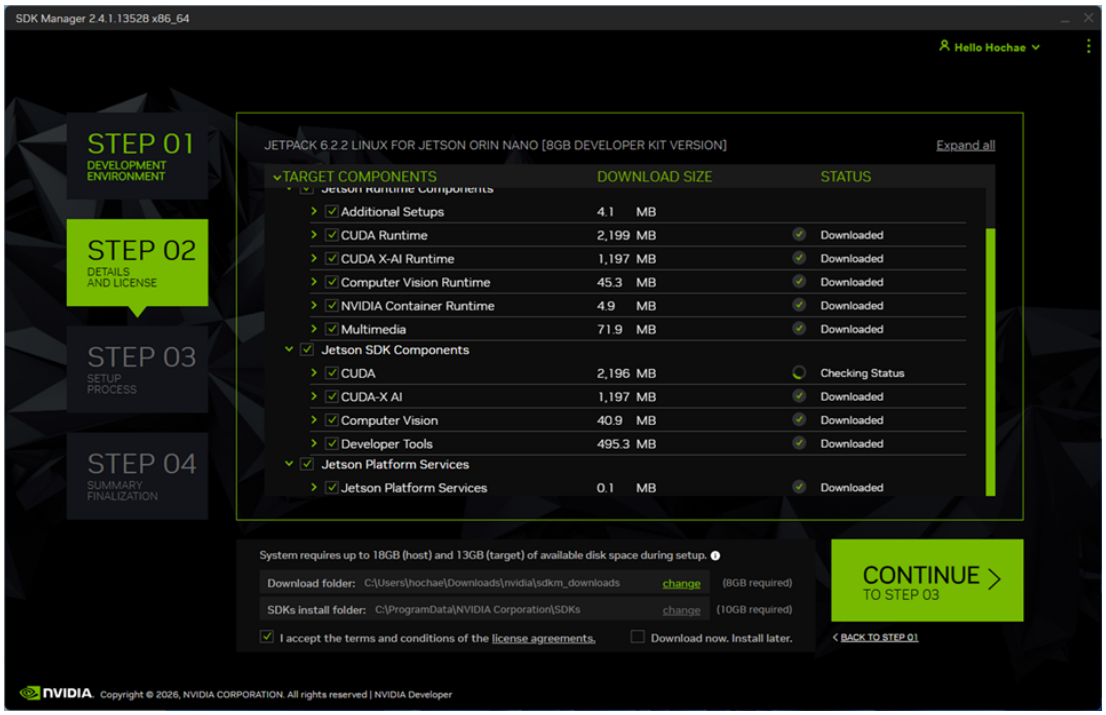
- SDK Step 01: 보드 연결을 자동으로 확인



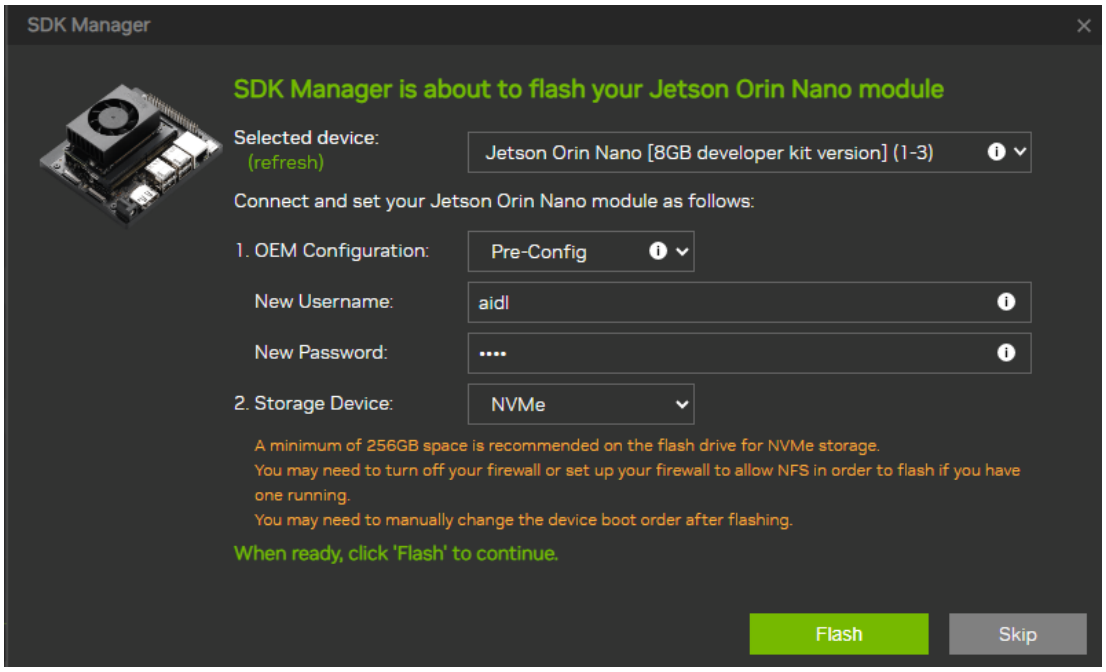
- SDK Product selection: 보드 연결이 되면 자동으로 선택 popup이 뜬다
  - Jeson Orin Nano[8GB developer kit version] 선택



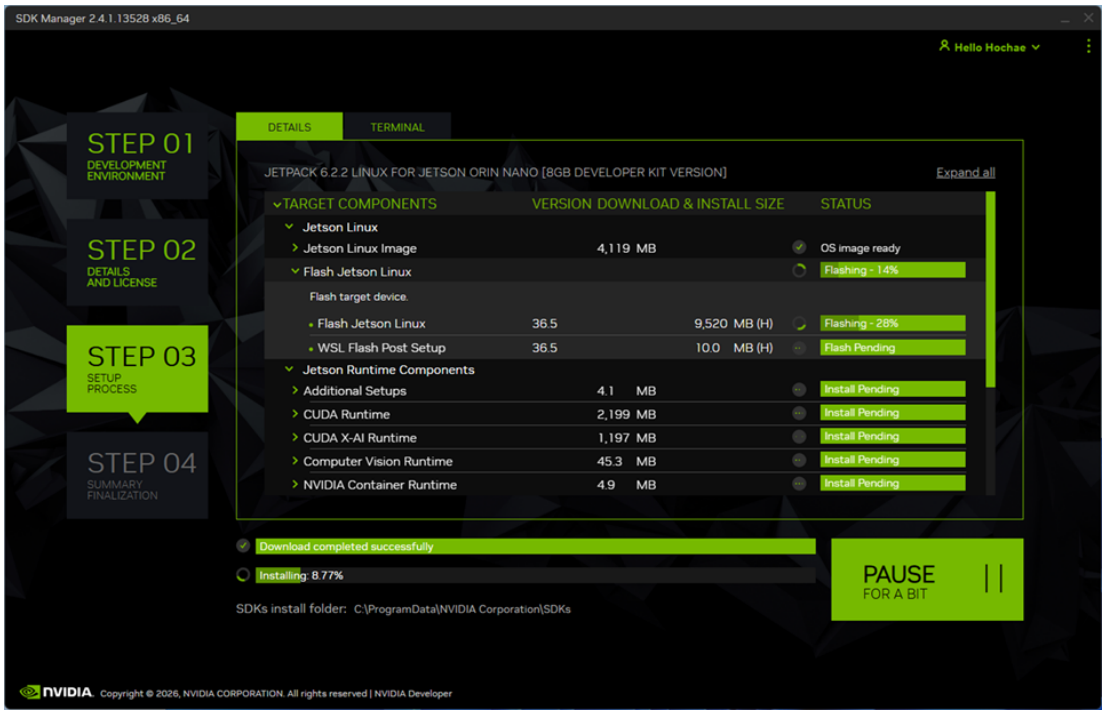
- SDK Step 02: Lincese 만 check하고 진행
  - 주의 사항: TARGET COMPONENT 전체 선택 확인 필수



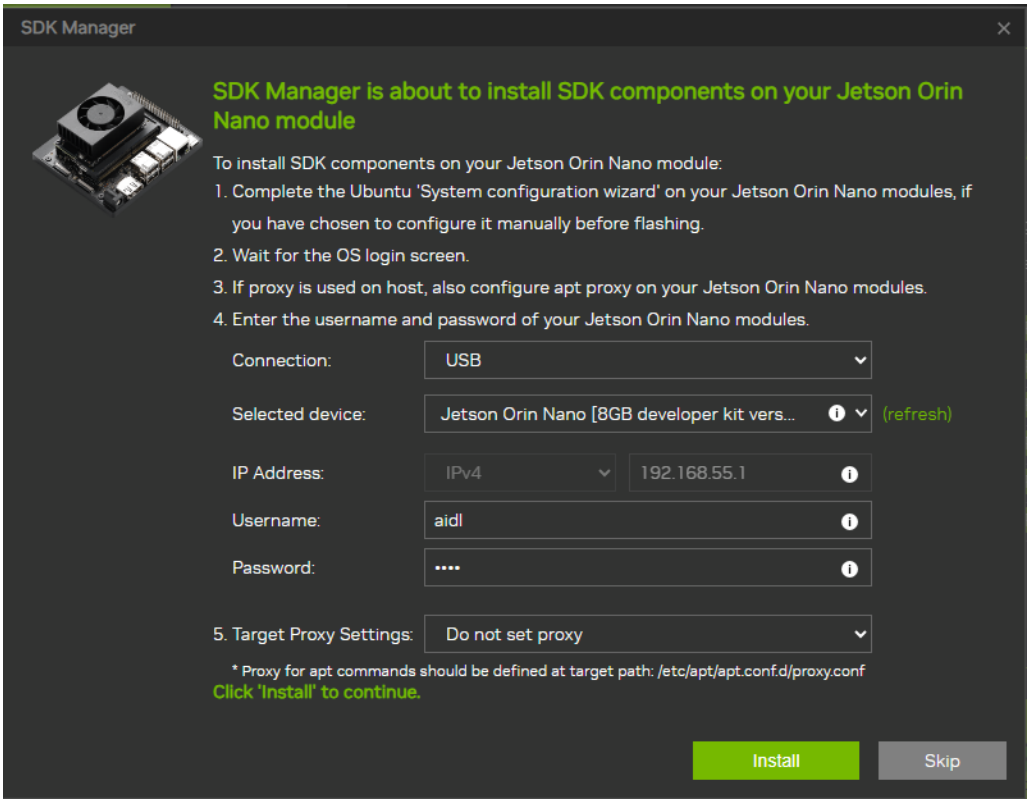
- SDK `OEM Configuration` & `Storage`: 초기 login 필요, 반드시 아래와 같이 지정한다.
  - New Username: `aidl`
  - New Password: `will`
  - Sotrage Device: `NVMe`
  - `Flash`로 다음 진행



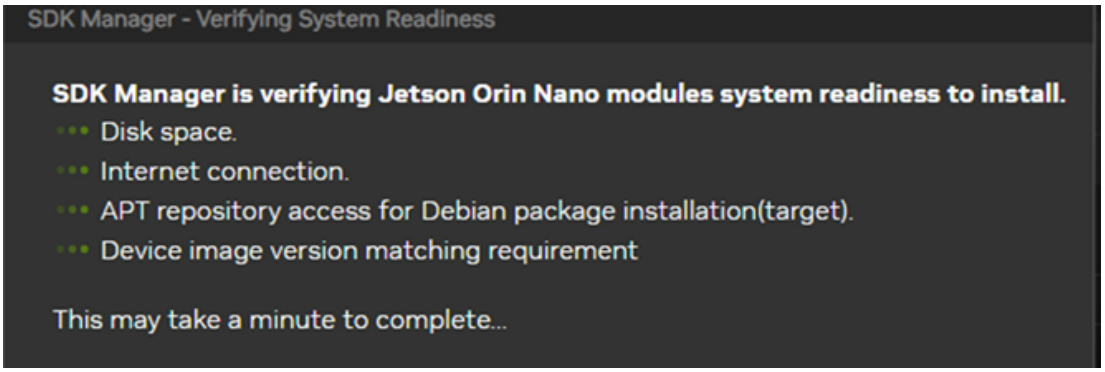
- SDK `Step 03`: `Download only` 를 unmark 하고 진행



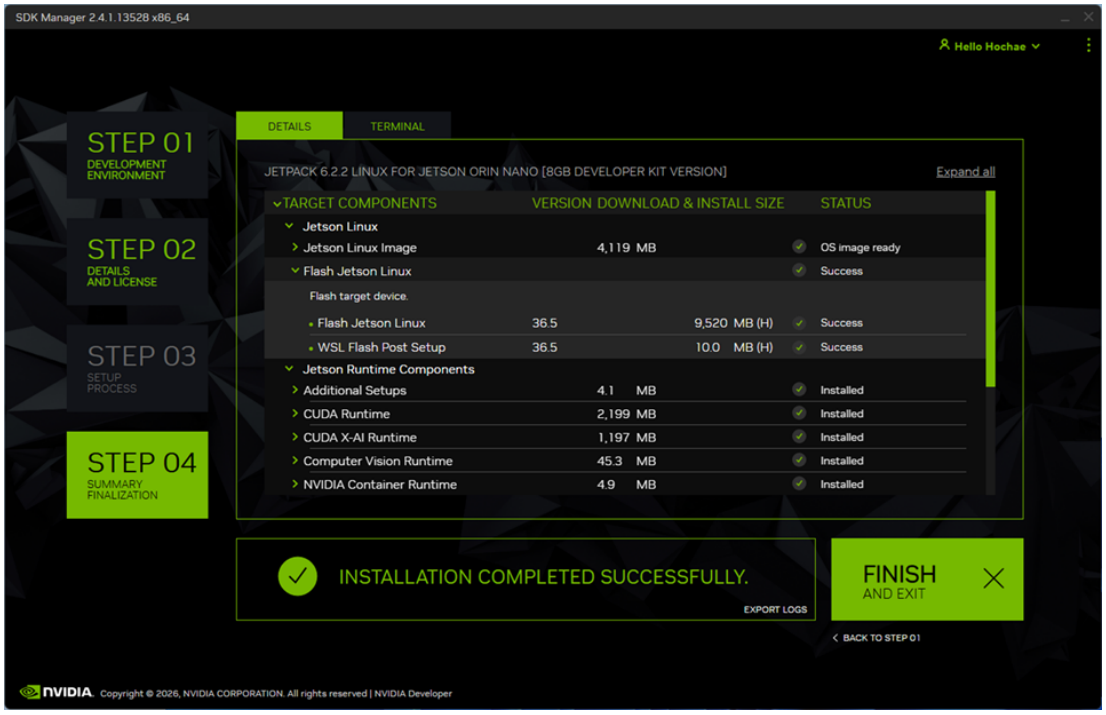
- SDK components install 시작 전에 확인 창이 뜬다. Install을 선택하고 진행



- verifying Jetson board 후 진행 됨



- SDK Step 04


SDK Manager 2.4.1.13528 x86_64
Hello Hochae
STEP 01
DEVELOPMENT ENVIRONMENT
STEP 02
DETAILS AND LICENSE
STEP 03
SETUP PROCESS
STEP 04
SUMMARY FINALIZATION
DETAILS
TERMINAL
JETPACK 6.2.2 LINUX FOR JETSON ORIN NANO [8GB DEVELOPER KIT VERSION]
Expand all
TARGET COMPONENTS
VERSION
DOWNLOAD & INSTALL SIZE
STATUS
Jetson Linux
Jetson Linux Image 4,119 MB OS image ready
Flash Jetson Linux Success
Flash target device.
Flash Jetson Linux 36.5 9,520 MB (H) Success
WSL Flash Post Setup 36.5 10.0 MB (H) Success
Jetson Runtime Components
Additional Setups 4.1 MB Installed
CUDA Runtime 2,199 MB Installed
CUDA X-AI Runtime 1,197 MB Installed
Computer Vision Runtime 45.3 MB Installed
NVIDIA Container Runtime 4.9 MB Installed
INSTALLATION COMPLETED SUCCESSFULLY.
EXPORT LOGS
FINISH AND EXIT
BACK TO STEP 01
NVIDIA Copyright © 2026, NVIDIA CORPORATION. All rights reserved | NVIDIA Developer

Jetson Orin Nano: SSD setup guid

SDK manager를 통하여 기본 tool과 SDK를 install한 경우에 대한 setup guide를 정리한다.

1. Jetson에 SSH을 통해 login

- powershell을 열고 아래 명령으로 jetson board에 login 한다.

```
ssh  - Y aidl@jetson-000.local
```

- 처음 연결 시 연결 진행 여부를 묻는 message가 출력됨. yes를 입력하고 진행
- `host name으로 연결이 안될 경우 ip로 진행한다.
- passwd를 입력하고 login 한다.
- login 되면 아래 명령으로 ubuntu update 와 upgrade를 진행한다.

```
sudo apt update
sudo apt upgrade
```

1. install tools

- check cuda version

```
nvcc --version
```

- nvcc가 없다고 나오면 아래 명령으로 cuda/bin 을 PATH에 추가

```
echo 'export PATH=/usr/local/cuda/bin:$PATH' >> ~/.bashrc
echo 'export LD_LIBRARY_PATH=/usr/local/cuda/lib64:$LD_LIBRARY_PATH' >> ~/.bashrc
```

- cuda-tookit-12 install

```
sudo apt install cuda-toolkit-12
```

- nvidia-container, apt-utils: to save time, jq: For docker configuration

```
sudo apt install -y nvidia-container apt-utils jq
```

- jetson-stats을 아래 명령을 이용하여 super user 권한으로 install : for jtop

```
sudo -H pip3 install -U jetson-stats
```

- reboot system

```
sudo reboot
```

- jtop에서 jetpack version missing issue: 아래 file을 수정, 진행하지 않는다.

```
sudo vi /usr/local/lib/python3.10/dist-packages/jtop/core/jetson_variables.py
```

tip

- jetpack version을 정확히 확인하는 방법

```
sudo apt-cache show nvidia-jetpack | grep "Version:"
```

Jetson Orin Nano: Docker on SSD

Docker setup

1. check docker status

- 아래 명령으로 docker info를 확인한다.

```
docker info
```

- permission denied while trying to connect to the docker API at unix:///var/run/docker.sock
- 권한 문제: 매번 sudo 사용하는대신 USER를 docker group에 추가

```
sudo usermod -aG docker $USER
newgrp docker
```

- docker status 확인: 기본 setting runc

```
$ docker info |grep -e Runtime -e Root
Runtimes: io.containerd.runc.v2 nvidia runc
Default Runtime: runc
Docker Root Dir: /var/lib/docker
```

2. Docker config for GPU

Default Runtime을 nvidia로 바꾸어 GPU를 사용하게 설정

- /etc/docker/daemon.json File 수정 전

```
$ cat /etc/docker/daemon.json
{
    "runtimes": {
        "nvidia": {
            "args": [],
            "path": "nvidia-container-runtime"
        }
    }
}
```

- 수정

```
sudo jq '. + {"default-runtime": "nvidia"}' /etc/docker/daemon.json | \
sudo tee /etc/docker/daemon.json.tmp && \
sudo mv /etc/docker/daemon.json.tmp /etc/docker/daemon.json
```

- 수정 후

```
{
"runtimes": {
    "nvidia": {
    "args": [],
    "path": "nvidia-container-runtime"
    }
},
"default-runtime": "nvidia"
}
```

- Restart docker

```
sudo systemctl daemon-reload && sudo systemctl restart docker
```

3. Final verification

- Default Runtime: nvidia

```
$ docker info | grep -e Runtime -e Root
Runtimes: io.containerd.runc.v2 nvidia runc
Default Runtime: nvidia
Docker Root Dir: /var/lib/docker
```

Ollama quick install guid

1. Install Ollama

- 아래 명열으로 ollama를 install 한다.

```
curl -fsSL https://ollama.com/install.sh | sh
```

- curl (Client URL): 터미널(CLI) 환경에서 URL을 이용해 서버와 데이터를 주고받거나, 서버에 특정 기능(요청)을 수행하도록 명령하는 도구
- -fsSL : option, 에러가 나면 조용히 실패하고, 진행은 숨기되, 올바른 주소로 자동 이동해서 데이터를 가져와

1. f: fail을 무시 2. s: silence, 진행 상황 숨기기 3. S: Show, 치명적인 에러 보이기 4. L: Location, redirect 주소 추적

- |: pipe, 읽어온 data를 다음 명령 sh에 전달하여 수행

2. Pull a model: donwload model

- 아래 명령으로 gemma3:4b model을 download한다.

```
ollama pull gemma3:4b
```

3. 현재 Swap 메모리 확인하기

터미널에서 다음 명령어를 입력하여 현재 설정된 Swap 용량을 확인하세요.

```
free -h
```

또는 더 상세한 정보를 보려면:

```
swapon --show
```

- Swap: 항목의 Total 용량이 16G 이상 확보, 원활한 LLM model 구동을 위해

4. Swap 메모리 늘리기 (Step-by-Step)

기존 Swap을 끄고 16GB로 새로 설정하는 방법

① 기존 Swap 비활성화 (선택 사항)

```
sudo swapoff -a
```

② Swap 파일 생성 (16GB 기준)

`fallocate` 명령어를 사용하여 16GB 크기의 파일을 생성

```
sudo fallocate -l 16G /swapfile
```

③ 권한 설정 (보안상 중요)

```
sudo chmod 600 /swapfile
```

④ Swap 포맷 및 활성화

```
sudo mkswap /swapfile
sudo swapon /swapfile
```

5. 재부팅 후에도 자동 적용하기

위 설정은 재부팅하면 사라짐. 영구적으로 적용하려면 `/etc/fstab` 파일을 다음과 같이 수정.

1. 파일 열기:

```
sudo vi /etc/fstab
```

2. 파일 맨 아래에 다음 내용을 추가하고 저장 후 종료:

```
/swapfile none swap sw 0 0
```

6. 확인 및 마무리

다시 `free -h`를 입력하여 `Swap: Total`이 16Gi 근처로 나오는지 확인.

vLLM vs Ollama 비교 요약

| 구분 | vLLM (기업/서버급) | Ollama (개인/에지급) | | --- | --- | --- | | 주요 목표 | 고처리량(High Throughput), 서빙 효율화 | 간편한 사용, 개인화된 로컬 실행 | | 메모리 관리 | PagedAttention (메모리 선점형) | 온디맨드(On-demand) 동적 할당 | | 설정 난이도 | 높음 (Jetson 전용 빌드/설정 필요) | 매우 낮음 (스크립트 한 줄 설치) | | 추천 하드웨어 | 넉넉한 VRAM (Orin NX, AGX 이상) | 제한된 리소스 (Orin Nano 8GB) | | 장점 | 여러 명이 동시 접속해도 속도 저하 적음 | 설치가 쉽고 다양한 양자화 모델 지원 |

Jetson Orin nano board setup: venv for Computer Vision

Jetson board에서 object detection 개발 환경을 구축한다.

Virtual environemnt setup

1. install python3.10-venv on ubuntu

version은 현재 python version을 확인하고 결정

```
sudo apt install python3.10-venv
```

2. working directory에 venv 설정

- work directory를 만들고 change directory

```
mkdir work && cd work
```

- 다음 명령으로 venv 이름으로 virtual evironment setup

--system-site-packages option을 이용하여 현재 jetpack version 환경을 그대로 사용

```
python -m venv --system-site-packages venv
```

- activate venv

```
source ~/work/venv/bin/acitvate
```

prompt가 아래와 같이 바뀌었는지 확인

```
(venv) aidl@jetson-200:~$
```

3. VS code remote ssh 연결로 jetson board 개발 환경 구축

- VS code에서 새창 열기를 진행한다.
- Remote-ssh 확장 pack이 install 되어 있는지 확인하고 없으면 install
- ssh 연결 추가를 선택하고 아래와 입력하고 .ssh/config를 확인한다.

```
ssh -X aidl@jetson-000.local
```

- SSH list 에서 연결할 보드를 선택하고 현재 창에서 연결을 진행하다.
  1. 보드의 system을 linux로 선택한다.
  2. passwd를 입력하고 진행한다.
  3. EXPLORER 창에서 Open Floder를 선택하여 jetson의 workding folder를 연다.
- 연결이 되었으면 필요한 파일들을 working space 에 drag & drop으로 copy 한다.
  1. examples_jetson_260530.zip을 unzip 한 example folder
  2. utils.zip을 unzip 하고 utils/pip_packages/requirements.txt file
- copy 완료 후 terminal 창에서 venv를 activate 하고 work directory 안에서 다음 명령을 실행한다.

```
pip install  -r requirements.txt
```

ultralytics 와 pytorch 설치

ultralytics YOLO를 사용하기 위해서 pytorch를 install

1. copy pytorch .whl file to board

- unzip한 utils/torch_whl folder를 board에 copy
- torch_whl folder에서 다음 명령을 수행하여 torch를 install

```
pip install --no-cache torch-2.3.0-cp310-cp310-linux_aarch64.whl
pip install --no-cache torchvision-0.18.0a0+6043bc2-cp310-cp310-linux_aarch64.whl
pip install --no-cache torchaudio-2.3.0+952ea74-cp310-cp310-linux_aarch64.whl
```

2.ultralytics install

- 다음 명령을 수행하여 numpy와 pytorch version을 유지하고 install

```
pip install ultralytics 'numpy==1.26.4' 'torch==2.3'
```

Open WebUI on Jetson Orin Nano

1. run Open WebUI on Docker

Open WebUI는 Docker를 이용해 실행하므로 별도의 install 과정은 없이 다음 명령을 수행하면 된다.

```
docker run -d \
  --network=host \
  -v open-webui:/app/backend/data \
  -e OLLAMA_BASE_URL=http://127.0.0.1:11434 \
  --name open-webui \
  --restart always \
  ghcr.io/open-webui/open-webui:main
```

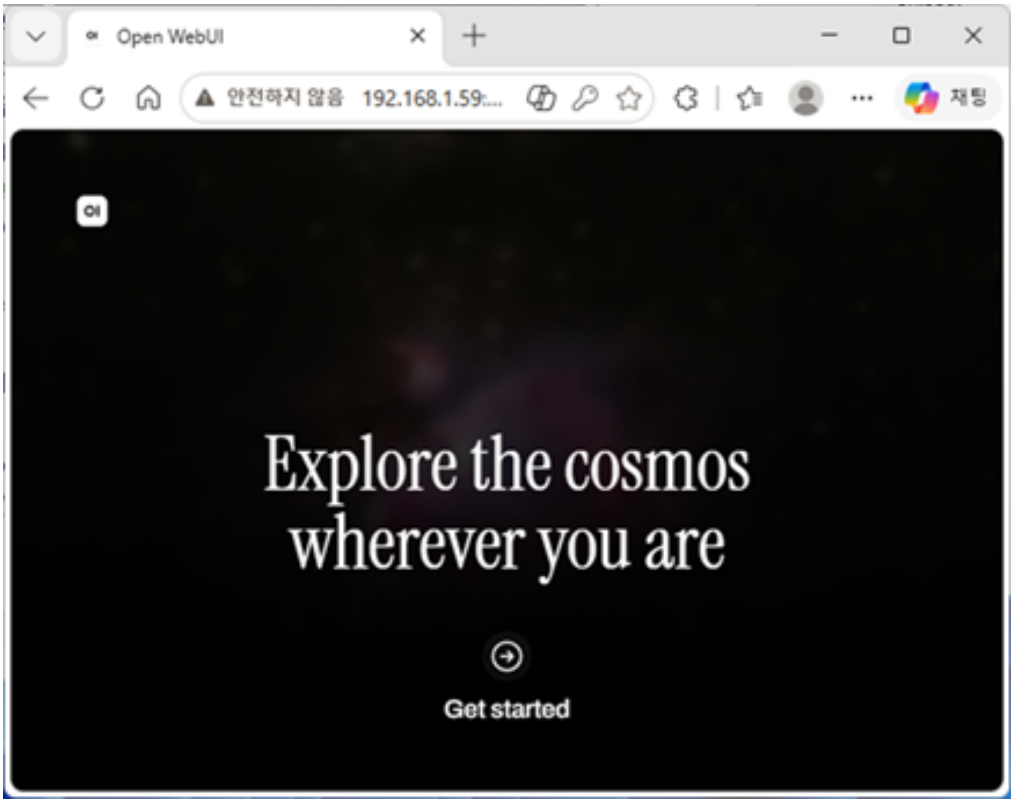
- `run`: 새로운 docker container를 생성하고 실행하라는 명령어
- `-d` (Detached mode): container를 background에서 실행
- `--network=host`: host PC의 network 환경을 공유하겠다는 설정
- `-v` (Volume): docker와 host가 공유하는 영역,
  - `open-webui:/app/backedn/data` docker 내 경로
  - host pc 경로: /var/lib/docker/volumes/open-webui/_data/
- `-e' (Environment): Container 내부 환경 변수,
  - `OLLAMA_BASE_URL=http://127.0.0.1:11434` ollama 주소
  - Open WebUI에게 인공지능 모델을 구동하는 backend engine인 ollama 주소를 알려줌
  - `--network=host`로 하였으므로 127.0.0.1 (localhost address) 은 jetson 의 ollama를 지정하는 것임.
  - `:11434` : ollama service 의 port #
- `--name ope-webui`: 생성될 container의 이름 지정 docker image id 대신 사용 가능
- `--restart always`: 자동 재시작 정책 적용
- `ghcr.io/open-webui/open-webui:main`: docker image 주소와 tag

ghcr (GitHub Container Registry)에 등록된 Open WebUI의 가장 최신 안정 버전(main)

2. Web-browser를 열고 접속해 보자

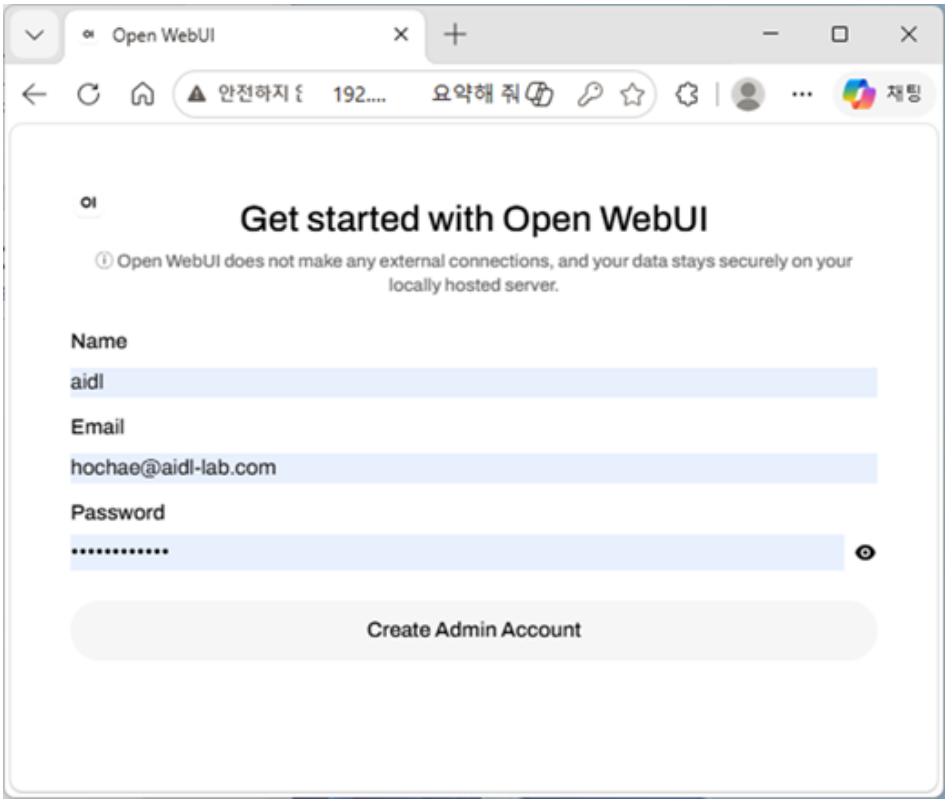
```
http://<jetson.ip>:8080
```

- web-browser를 열고 점속

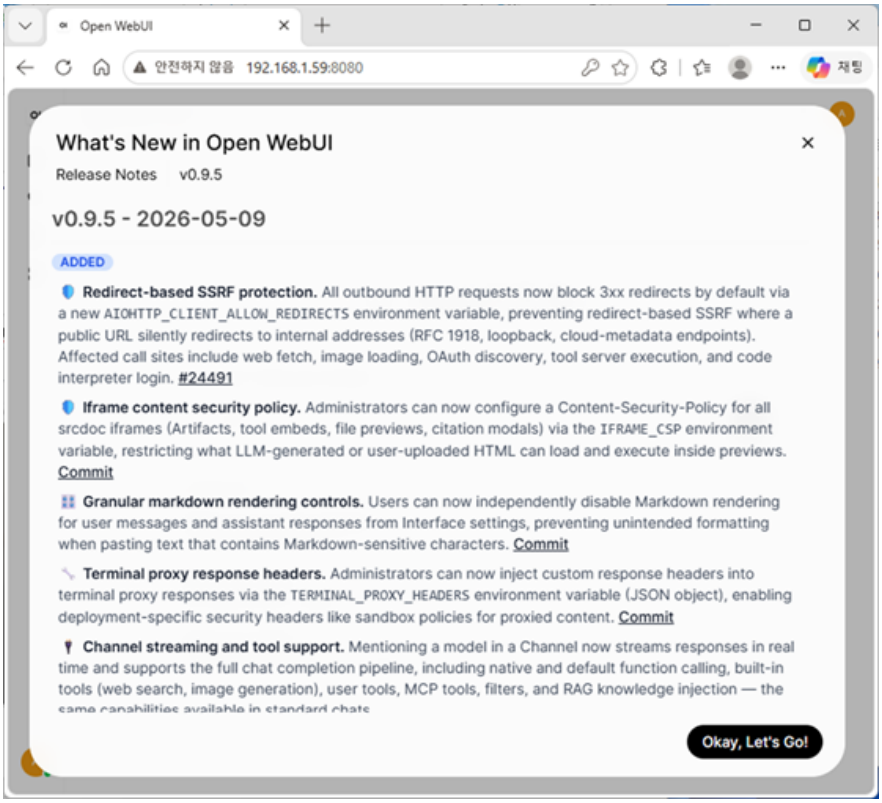


3. Get started를 선택하고 login 과정을 거치자

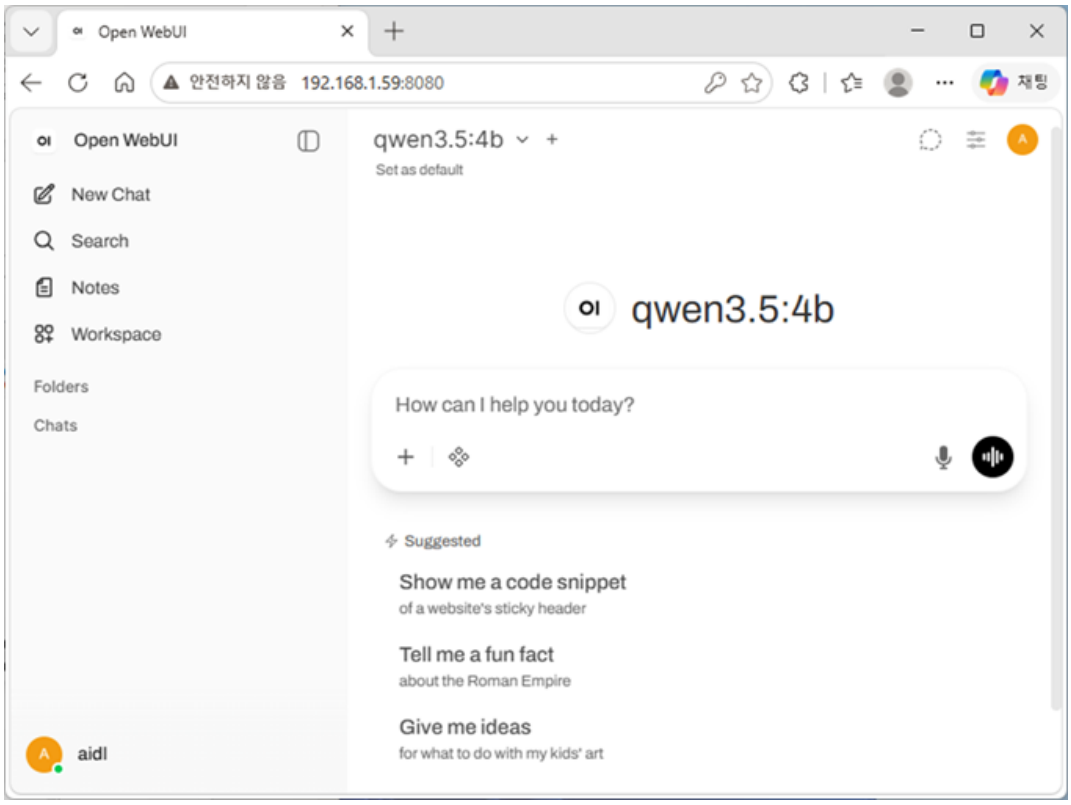
- admin 계정이 없다면 다음과 같이 만들고 login



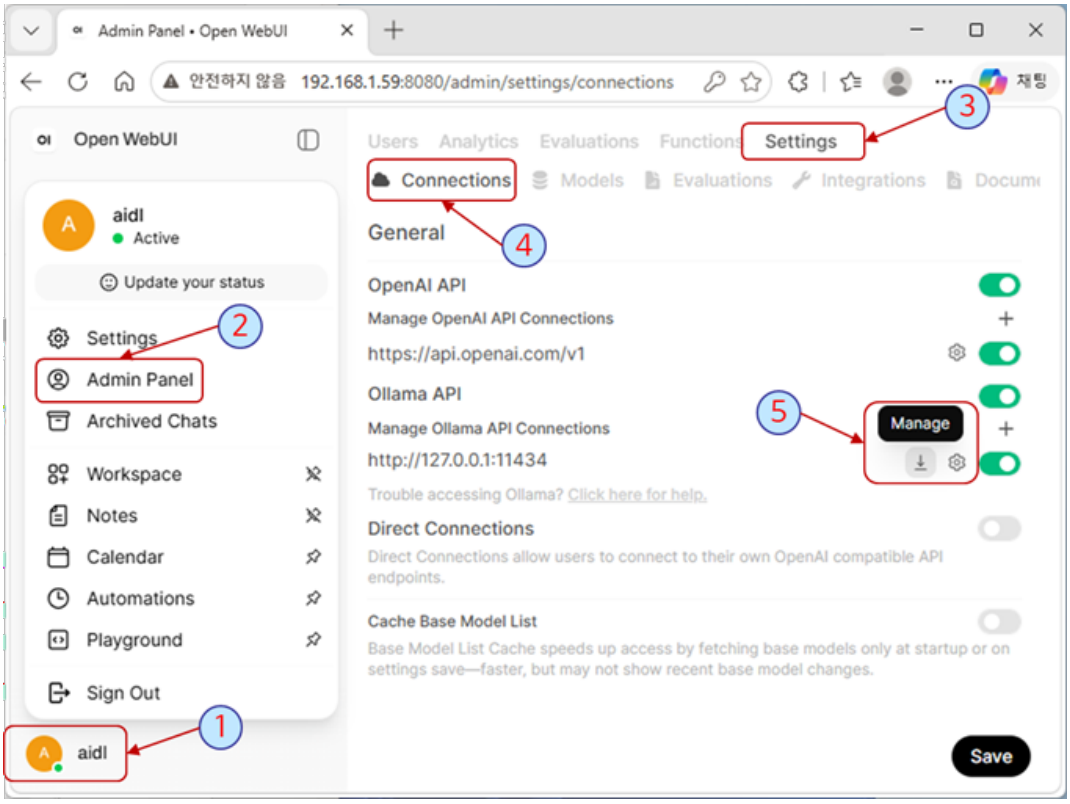
- Open WebUI version 정보 확인: 처음 연결 시



- Chatting 창: looks like open LLM models' site



- ollama model을 pull 해보자
  - `Admin Panel -> Settings -> Connections -> ollama manage 선택`



  - Manage Ollama popup 에서 model name을 적고 pulling

